

Bank marketing.

Isaac, Prisca, Zakia



Scanne le QR Code

Et Réponds a la question



Sommaire.

01 **Introduction.**

02 **Workflow du projet.**

03 **EDA.**

04 **Machine Learning.**

05 **Prédiction.**

06 **Conclusion.**


01 Introduction.

*Selon vous, qui est le plus susceptible de souscrire à un dépôt à terme *?*



MATTHIEU

- 40 ans
- Ouvrier
- + 1477€




JEAN

- 59 ans
- Retraité
- + 2867€



SARAH

- 33 ans
- Manager
- + 1 368€




- dépôt à terme * : compte d'épargne où le client bloque son argent pendant une durée fixée à l'avance, en échange d'un taux d'intérêt garanti plus avantageux.
- Problématique : Prédire quels types de clients est plus susceptible de souscrire au dépôt à terme ?

02

Workflow du projet

Methodologie



- 1 Création repo (synch constante)
- 2 DL du dataset
- 3 Export du dataset clean post EDA
- 4 Import DS clean pour création du Dashboard
- 5 Déploiement vers Streamlit (.py)
- 6 Import du DS pour Machine learning
- 7 Export du modèle en format joblib
- 8 Déploiement du modèle sur SStreamlit (via Local .py)
- 9 Déploiement de Streamlit sur HUGGING FACE (via Local .py)


02

Workflow du projet

Stack



Python
Jupyter Notebook
Pandas
Python-dotenv
Matplotlib & Seaborn
Plotly
Scikit-learn

Joblib
AWS S3
Boto3
Streamlit
Docker
Hugging Face
Git
GitHub



**ANALYSE EXPLORATOIRE
EDA**

Prisca



MACHINE LEARNING

Lakia



Isaac

**DATA ENGINEERING
BACK END**

03

EDA

Objectifs

1-Identifier les variables clés

2-Comprendre le profil des
clients convertisseurs

3-Construire un modèle
prédictif performant

Quelles caractéristiques (variables) impactent le plus la décision du client ?

DASHBOARD



04

Machine Learning

LOGISTIC REGRESSION

1

RÉSULTATS DU MODÈLE (Test)

76,18%

Accuracy

38%

F1_Score

27,7%

Precision
Score



60,49%

Recall

74%

AUC

Matrice de confusion



04

Machine Learning

RANDOM FOREST

- Gestion de la non linéarité
- Interactions croisées
- Robustesse aux "outliers"
- Gestion du déséquilibre

2

RÉSULTATS DU MODÈLE

81,95%

Train Score


81,69%

Test Score
(Réal)

0,26%

Écart
(Overfitting)

Performance Business du Modèle C



04 Machine Learning

Le modèle améliore-t-il réellement le processus décisionnel ?

SEUIL		PRÉCISION		RECALL		CLIENTS CIBLÉS		PROFIT ESTIMÉ (€)
0.30		12.2%		98.2%		8546		18,440 €
0.40		16.9%		82.8%		5195		35,650 €
0.45		22.7%		70.8%		3303		41,870 €
0.50		32.7%		53.5%		1730		39,300 €
0.60		44.9%		37.9%		893		31,170 €
0.70		56.7%		24.9%		464		21,660 €

🏆 MEILLEUR SCÉNARIO : Seuil de 0.45 (Profit max : 41,870 €)

💰 LA LOGIQUE DU CALCUL (ROI) :

✅ GAINS : +100€ pour chaque vente réussie (Vrais Positifs).


❌ COÛTS : -10€ pour chaque appel déclenché (qu'il réussisse ou non).

👉 FORMULE : Profit = (Nombre de Ventes x 100€) - (Nombre d'Appels x 10€)

L'objectif est d'arrêter d'appeler inutilement pour maximiser la marge.

05 Prédiction

Nos personas





Le client a moins de 15% de chances de souscrire.

Le client est indécis.


Forte probabilité.



MATTHIEU



JEAN



SARAH

SIMULATION

Conclusion.

En transformant un jeu de données brut de 45 000 contacts en un simulateur de rentabilité, nous avons franchi le pas entre la statistique et la gestion de la performance.

- Efficacité Chirurgicale
- Productivité Commerciale
- Rentabilité Pilotée

Perspectives

L'Optimisation Temporelle

L'objectif est de prédire non seulement qui va souscrire, mais surtout le meilleur moment pour lancer les campagnes.

Continuous Learning

Passer d'un modèle statique à un modèle qui apprend en temps réel en réinjectant chaque jour les résultats des appels effectués

